

Министерство науки и высшего образования Российской Федерации Федеральное государственное бюджетное образовательное учреждение высшего образования

«Московский государственный технический университет имени Н.Э. Баумана (национальный исследовательский университет)» (МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ ИНФОРМАТИКА И СИСТЕМЫ УПРАВЛЕНИЯ

КАФЕДРА КОМПЬЮТЕРНЫЕ СИСТЕМЫ И СЕТИ (ИУ6)

НАПРАВЛЕНИЕ ПОДГОТОВКИ 09.04.01 Информатика и вычислительная техника

МАГИСТЕРСКАЯ ПРОГРАММА **09.04.01/07 Интеллектуальные системы анализа, обработки и интерпретации больших данных**

ОТЧЕТ

по лабораторной работе № 2

Название: Оптимизация за	<u>тросов. С</u>	Основы 2	<u>EXPLAIN</u>	в Postgr	eSQL.
<u>Индексация</u>					

Дисциплина: Технология параллельных систем баз данных

Студент	ИУ6-12М		С.В. Астахов
	(Группа)	(Подпись, дата)	(И.О. Фамилия)
Преподаватель			
		(Подпись, дата)	(И.О. Фамилия)

Введение

1. Цель работы: формирование следующей компетенции: студент должен получить навыки работы с командой EXPLAIN. Он также должен познакомиться с эффективными методами индексации в PostgreSQL.

Ход выполнения

2. Основы **EXPLAIN**.

Создадим таблицу, заполним ее миллионом записей, выполним команду EXPLAIN для запроса выборки всех записей, затем добавим записи в таблицу и выполним EXPLAIN повторно. Как видно из рисунка 1, при вставке новых записей в таблицу, ее статистика не обновляется автоматически, что приводит к повторяющимся результатам при вызове EXPLAIN.

```
trickster@Ubuntul:~$ sudo -u admin psql iu6
[sudo] password for trickster:
could not change directory to "/home/trickster": Permission denied
psql (9.6.24)
Type "help" for help.
iu6=# CREATE TABLE foo (cl integer, c2 text);
CREATE TABLE
iu6=# INSERT INTO foo
  SELECT i, md5(random()::text)
FROM generate series(1, 1000000) AS i;
INSERT 0 1000000
iu6=# EXPLAIN SELECT * FROM foo;
                            QUERY PLAN
 Seq Scan on foo (cost=0.00..18918.18 rows=1058418 width=36)
(1 row)
iu6=# INSERT INTO foo
  SELECT i, md5(random()::text)
FROM generate series(1, 10) AS i;
INSERT 0 10
iu6=# EXPLAIN SELECT * FROM foo;
                            QUERY PLAN
 Seq Scan on foo (cost=0.00..18334.00 rows=1000000 width=37)
(1 row)
iu6=# INSERT INTO foo
  SELECT i, md5(random()::text)
FROM generate geries(1, 10) AS i;
INSERT 0 10
iu6=# EXPLAIN SELECT * FROM foo:
                            QUERY PLAN
 Seg Scan on foo (cost=0.00..18334.00 rows=1000000 width=37)
(1 row)
```

Рисунок 1 — пример EXPLAIN без обновления статистики

Обновим статистику и убедимся, что результаты вызова EXPLAIN изменились, так как была собрана актуальная статистика (рисунок 2).

```
iu6=# ANALYZE foo;
ANALYZE
iu6=# EXPLAIN SELECT * FROM foo;
QUERY PLAN

Seq Scan on foo (cost=0.00..18334.20 rows=1000020 width=37)
(1 row)
```

Рисунок 2 — обновление статистики по таблице Используем EXPLAIN ANALYZE, чтобы увидеть время, потраченное на реальное исполнение запроса и количество считанных строк.

```
iu6=# EXPLAIN ANALYZE SELECT * FROM foo;

QUERY PLAN

Seq Scan on foo (cost=0.00..18334.20 rows=1000020 width=37) (actual time=1.076..55.755 rows=1000020 loops=1) Planning time: 18.054 ms
Execution time: 77.929 ms
(3 rows)
```

Рисунок 3 — пример выполнения EXPLAIN ANALYZE

Добавим дополнительное условие в запрос, увидим, что стоимость выполнения запроса изменилась, а количество выбранных строк уменьшилось (рисунок 4).

Рисунок 4 — исследование запроса с дополнительным условием

Создадим индекс для c1 и попробуем повторить запрос. Индекс использоваться не будет, так как выбирается большая доля записей из таблицы и использование индекса неэффективно (рисунки 5, 6).

```
iu6=# create index on foo (c1);
CREATE INDEX
```

Рисунок 5 — создание индекса

Рисунок 6 — запрос после создания индекса

Изменим запрос так, чтобы выбиралось малое число записей. Теперь индекс будет использоваться (рисунок 7).

```
iu6=# EXPLAIN ANALYZE SELECT * FROM foo WHERE c1 < 500;

QUERY PLAN

Index Scan using for c1 idx on foo (cost=0.42..24.15 rows=458 width=37) (actual time=0.015..0.139 rows=519 loops=1)
Index Cond: (c1 < 500)
Planning time: 0.084 ms
Execution time: 0.171 ms
(4 rows)
```

Рисунок 7 — запрос с использованием индекса

Усложним запрос, добавив условие по текстовому полю. Сначала будет проходить фильтрация, а затем — сканирование по индексу (рисунок 8).

Рисунок 8 — запрос с фильтрацией по текстовому полю

Уберем условие по индексированному полю, теперь будет происходить полное сканирование таблицы, так как по полю с2 индекс не создан (рисунок 9).

Рисунок 9 — запрос без условия по полю с1

Создадим индекс по полю с2, теперь он будет использоваться в запросе (рисунок 10).

Рисунок 10 — запрос по индексированному текстовому полю

Удалим индекс по полю с1 и выполним запрос с упорядочиванием, будет использован метод сортировки external merge.

```
iu6=# EXPLAIN ANALYZE SELECT * FROM foo ORDER BY c1;

QUERY PLAN

Sort (cost=172685.18..175185.23 rows=1000020 width=37) (actual time=474.441..566.653 rows=1000020 loops=1)

Sort Key: c1

Sort Method: external merge Disk: 45952kB

-> Seq Scan on foo (cost=0.00..18334.20 rows=1000020 width=37) (actual time=0.007..89.545 rows=1000020 loops=1)

Planning time: 0.246 ms

Execution time: 595.282 ms
(6 rows)
```

Рисунок 11 — запрос с упорядочиванием

Увеличим объем используемой оперативной памяти — теперь будет использована сортировка quicksort (рисунок 12).

Рисунок 12 — запрос с упорядочиванием после изменения настроек

Создадим индекс для поля с1 и повторим запрос. Так как в индексе значения упорядочены, сортировка не понадобится (рисунок 13).

```
iu6=# create index on foo (c1);
CREATE INDEX
iu6=# EXPLAIN ANALYZE SELECT * FROM foo ORDER BY c1;

QUERY PLAN

Index Scan using for c1 idx on foo (cost=0.42..34327.72 rows=1000020 width=37) (actual time=0.167..141.383 rows=1000020 loops=1)
Planning time: 0.123 ms
Execution time: 168.310 ms
(3 rows)
```

Рисунок 13 — запрос с упорядочиванием по индексу

Создадим новую таблицу и соберем для нее статистику (рисунок 14).

```
iu6=# CREATE TABLE bar (c1 integer, c2 boolean);
INSERT INTO bar
   SELECT i, i%2=1
   FROM generate series(1, 500000) AS i;
CREATE TABLE
INSERT 0 500000
iu6=# ANALYZE bar;
ANALYZE
```

Рисунок 14 — создание новой таблицы

Выполним соединение новой таблицы со старой, затем создадим для нее индекс и выполним соединение повторно. Тип соединения изменится из-за наличия индексов (рисунок 15).

Рисунок 15 — соединение таблиц

Очистим кэш PostgreSQL и 3 раза обратимся к таблице foo. При каждом запросе ее часть будет кэшироваться для ускорения последующих обращений (рисунок 16).

```
iu6=# \q
trickster@Ubuntul:~$ sudo service postgresql stop
[sudo] password for trickster:
trickster@Ubuntul:~$ sudo sync
trickster@Ubuntul:~$ sudo su root
root@Ubuntul:/home/trickster# echo 3 > /proc/sys/vm/drop caches
root@Ubuntul:/home/trickster# exit
trickster@Ubuntul:~$ sudo service postgresql start
trickster@Ubuntul:~$ sudo -u admin psql iu6
could not change directory to "/home/trickster": Permission denied
psql (9.6.24)
Type "help" for help.
iu6=# EXPLAIN (ANALYZE, BUFFERS) select * from foo;
                                                      QUERY PLAN
 Seq Scan on foo (cost=0.00..18334.20 rows=1000020 width=37) (actual time=0.678..609.805 rows=1000020 loops=1)
   Buffers: shared read=8334
 Planning time: 10.636 ms
 Execution time: 646.710 ms
(4 rows)
iu6=# EXPLAIN (ANALYZE, BUFFERS) select * from foo;
                                                     OUERY PLAN
 Seq Scan on foo (cost=0.00..18334.20 rows=1000020 width=37) (actual time=0.032..73.622 rows=1000020 loops=1)
   Buffers: shared hit=32 read=8302
 Planning time: 0.036 ms
 Execution time: 114.004 ms
(4 rows)
iu6=# EXPLAIN (ANALYZE, BUFFERS) select * from foo;
                                                    OUERY PLAN
 Seq Scan on foo (cost=0.00..18334.20 rows=1000020 width=37) (actual time=0.051..69.548 rows=1000020 loops=1)
  Buffers: shared hit=64 read=8270
 Planning time: 0.079 ms
 Execution time: 105.050 ms
(4 rows)
```

Рисунок 16 — работа кэша

4. Эффективные методы индексации в PostgreSQL

Переподключимся к БД от имени пользователя postgres, создадим новую таблицу и индексы в ней (рисунок 17).

```
iu6=# \q
trickster@Ubuntul:~$ sudo -u postgres psql postgres
could not change directory to "/home/trickster": Permission denied
psql (9.6.24)
Type "help" for help.
postgres=# create table users
                serial
                            not null
        constraint users
            primary key,
                text
    email
    type text not null, extra jsonb not null, created at timestamp not null, updated at timestamp not null
CREATE TABLE
postgres=# alter table users
    owner to postgres;
create unique index users amail windex
    on users (email);
create unique index users in windex
    on users (id);
ALTER TABLE
CREATE INDEX
CREATE INDEX
```

Рисунок 17 — создание новой БД

Заполним новую БД (рисунок 18).

Рисунок 18 — заполнение таблицы Фрагмент заполненной таблицы представлен на рисунке 19.

postgres=# select * from id email	n users limit 10; type extra	created ot	updated et
1 user t@main.ru 2 user t@main.ru 3 user t@main.ru 4 user t@custom.ru 5 user t@yandex.ru 6 user t@main.ru 7 user t@main.ru 8 user t@custom.ru 9 user t@main.ru 10 user t@custom.ru (10 rows)	user {} user {} user {} admin {} user {} user {} user {} admin {} user {} user {}	2014-03-20	2016-06-29 07:09:04.50811 2016-07-12 07:22:32.417706 2016-12-02 14:40:39.278823 2016-07-31 07:21:33.25988 2016-11-05 19:45:20.07277 2016-02-18 03:08:51.526172 2017-10-23 02:56:59.11233 2017-09-07 17:25:57.696644 2017-06-19 08:52:07.530917 2017-11-16 22:20:34.150594

Рисунок 19 — фрагмент заполненной таблицы

Сравним выполнение указанных в задании запросов без использования индексов и при их наличии. Очевидно, при использовании индексов по полям из условий (where) не проводилось полного сканирования, а использовались индексы, что значительно ускоряло выполнение запросов (рисунки 20-22).

```
postgres=# EXPLAIN SELECT COUNT(*) FROM users WHERE email ILIKE '%yandex.ru';
                             QUERY PLAN
 Aggregate (cost=23522.81..23522.82 rows=1 width=8)
   -> Seq Scan on users (cost=0.00..22942.00 rows=232323 width=0)
         Filter: (email ~~* '%yandex.ru'::text)
(3 rows)
postgres=# create index trgm idx Wsers ⊜mail ON users USING gin (email gir trgm ops);
ERROR: operator class "gir trgm ops" does not exist for access method "gin"
postgres=# create extension pg trgm;
CREATE EXTENSION
postgres=# create index trgm idx users @mail ON users USING gin (email gir trgm ops);
CREATE INDEX
postgres=# EXPLAIN SELECT COUNT(*) FROM users WHERE email ILIKE '%yandex.ru';
 Aggregate (cost=16135.35..16135.36 rows=1 width=8)
   -> Bitmap Heap Scan on users (cost=2208.50..15554.54 rows=232323 width=0)
         Recheck Cond: (email ~~* '%yandex.ru'::text)
          -> Bitmap Index Scan on trgm idx users amail (cost=0.00..2150.42 rows=232323 width=0)
                Index Cond: (email ~~* '%yandex.ru'::text)
(5 rows)
```

Рисунок 20 — использование индекса по полю email

```
postgres=# EXPLAIN select * from users where updated at = '2016-03-22 01:51:57.261738'::timestamp and type = 'admin';

QUERY PLAN

Seq Scan on users (cost=0.00..25442.00 rows=1 width=50)
Filter: ((updated at = '2016-03-22 01:51:57.261738'::timestamp without time zone) AND (type = 'admin'::text))

(2 rows)

postgres=# create index users type updated ON users (type, updated at) WHERE type='admin'::text;

CREATE INDEX
postgres=# EXPLAIN select * from users where updated at = '2016-03-22 01:51:57.261738'::timestamp and type = 'admin';

QUERY PLAN

Index Scan using users type updated on users (cost=0.41..1251.17 rows=1 width=50)
Index Cond: (updated at = '2016-03-22 01:51:57.261738'::timestamp without time zone)

(2 rows)
```

Рисунок 21 — использование частичного индекса

Рисунок 22 — использование индекса по json-полю

Пример записей, которые были подсчитаны при фильтрации по полю email приведен на рисунке 23.

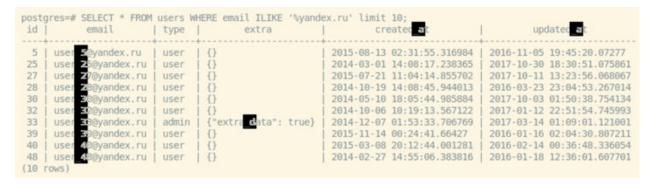


Рисунок 23 — пример отфильтрованных по email записей

Пример записей, которые были подсчитаны при фильтрации по полю extra приведен на рисунке 24.



Рисунок 24 — пример отфильтрованных по extra записей

Вывод: в ходе лабораторной работы были получены навыки работы с командой EXPLAIN. Было произведено знакомство с эффективными методами индексации в PostgreSQL. Все задание были успешно выполнены, а их результаты соответствуют требованиям.